

Equipe 1 - Segmentação de vasos sanguíneos da retina

Alunos:

Felipe Cordeiro
Kauã Ribeiro
Fernanda Rocha
Luís Lima
João Vitor Lobo
Rodrigo Pinheiro

Sumário

- Introdução – Fernanda
- Metodologia – Felipe/João Vitor
- Resultados – Kauã
- Conclusões – Luís

Introdução

- Leitura de retina;
- Retinopatia diabética, retinopatia hipertensiva, degeneração macular relacionada à idade (DMRI), descolamento da retina e glaucoma;
- U-net.



Metodologia




Dataset

Dataset

- Kaggle – Retina Blood Vessel
- 80 Imagens e 80 Máscaras

49.png



49.png




Normalização dos Dados

Normalização dos Dados

0	192	64	255	64	192	0
255	64	192	0	192	64	255
0	192	64	255	64	192	0
255	64	192	0	192	64	255
0	192	64	255	64	192	0
255	64	192	0	192	64	255
0	192	64	255	64	192	0

Arquitetura U-NET

Arquitetura U-NET




Treinamento e validação

Treinamento e validação

- Kaggle – Retina Blood Vessel
- 80 Imagens e 80 Máscaras

49.png




49.png



Resultados e conclusões

Resultados - UNET

- 32 de batch size e 80 epochs.
- 74% de accuracy e 81% de val_accuracy: precisão no treino e na validação.
- loss e val_loss: métricas (inadequadas) para o erro no modelo.



Resultados – UNET modificado

- Precision 0.1246 e val_precision 0.1195.
- Recall 1.0000 e val_recall 1.0000.
- Auc 0.5000 e val_auc = 0.5000.
- Overfitting reduzido, loss se manteve problemática.



Resultados – UNET modificado

Problema: loss negativa. Possíveis causas:

- Normalização inadequada do dataset.
- Learning rate alto demais.
- Valores inesperados recebidos pela função loss.

Bynary Cross-Entropy

$$\text{Loss} = -\frac{1}{\text{output size}} \sum_{i=1}^{\text{output size}} y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log (1 - \hat{y}_i)$$

- Calcula a diferença entre a distribuição de probabilidade prevista e a real.
- A variável assume apenas os valores 0 e 1, garantindo que Loss seja sempre maior ou igual a 0.

Binary Cross-Entropy no Keras

```
bce = target * log(output) + (1 - target) * log(1 - output)
return mean(-bce)
```

- Força as probabilidades preditas a estarem no intervalo (0, 1).
- Se target for maior que 1 e output for grande o bastante, bce seria positivo, logo $\text{mean}(-\text{bce})$ seria negativo.

Referências Bibliográficas

Referências Bibliográficas

González, Luís. Retinography. Disponível em: [Retinography | ICR Ophthalmologic Centre Barcelona \(icrcat.com\)](https://www.icrcat.com/). Acesso em: 10 de novembro de 2023.

Wagih,A. Retina Blood Vessel. Kaggle, 2023. Disponível em: <https://www.kaggle.com/datasets/abdallahwagih/retina-blood-vessel>>. Acesso em: 10 de novembro de 2023.

Band, Daniel. Retina Vessel Segmentation with TPU Test (Dice: 0.75). Kaggle, 2023. Disponível em: <https://www.kaggle.com/code/banddaniel/retina-vessel-segmentation-w-tpu-test-dice-0-75/input>>. Acesso em: 10 de novembro de 2023.

Yadav, Kiran An In-Depth Exploration of Loss Functions in Deep Learning. Disponível em: <https://www.linkedin.com/pulse/in-depth-exploration-loss-functions-deep-learning-kiran-dev-yadav/>>. Acesso em: 10 de novembro de 2023.